Part 1 分类评测指标

1. 指标定义及使用场景

指标	含义	使用场景
Accuracy	预测正确的样本占全部样本的比例：正确数除以 N。	分类整体表现；在类别较均衡、各种错误代价接近时比较适合。类别失衡时不太好（比如预测雨天，如果下雨天数本来就很少）。
MSE	预测值与真实值的差先平方，再对样本取平均：$\Sigma(y - \hat{y})^2 / N$。较大的误差受到更大惩罚。	回归或连续数值预测。不宜用作一般分类指标。
Precision	预测为正类的样本中真正为正类的比例（真阳性在所有阳性样本中所占的比例）：$TP / (TP + FP)$。	希望减少误报的任务。
Recall	真实正类样本中被识别出来的比例：$TP / (TP + FN)$。	希望减少漏报的任务。
F1	Precision 与 Recall 的调和平均：$2PR / (P + R)$，等价于 $2TP / (2TP + FP + FN)$。	需要同时考虑误报和漏报，尤其关注正类表现时。

Part 1 计算过程与测试

混淆矩阵	预测为 1	预测为 0
真实为 1	TP = 2	FN = 4
真实为 0	FP = 1	TN = 2

四项计数之和为 $2+1+4+2=9$。预测正确的是 TP 与 TN，共 4 个样本。

指标	代入及计算	结果
Accuracy	(TP + TN) / 9 = (2 + 2) / 9	4/9 ≈ 0.4444
Precision	TP / (TP + FP) = 2 / (2 + 1)	2/3 ≈ 0.6667
Recall	TP / (TP + FN) = 2 / (2 + 4)	1/3 ≈ 0.3333
F1	2TP / (2TP + FP + FN) = 4 / (4 + 1 + 4)	4/9 ≈ 0.4444

代码实现与基础自测

```
============================================================
实验：Part 1 - 分类评测指标
姓名：佟铭洋    学号：23300240009
时间：2026-10-06 10:06:45
============================================================
[BASIC] accuracy / MSE
 - accuracy expected 0.75 -> got 0.75 : PASS
 - mse      expected 0.6667 -> got 0.6667 : PASS
[PRF] precision / recall / f1 (binary)
 - precision expected 0.50 -> got 0.50 : PASS
 - recall    expected 0.50 -> got 0.50 : PASS
 - f1        expected 0.50 -> got 0.50 : PASS
```

Part 2 决策树

四种分裂准则

设节点类别比例为 p_c，左右子节点权重为 $w_L = N_L/N$、$w_R = N_R/N$。所有类别都参与统计，某个类别未出现在子节点时不产生该类别的求和项。

准则	节点不纯度与分裂得分
Information Gain	$H(y) = -\Sigma\, p_c \log_2(p_c)$；得分 = $H(y) - w_L\, H(L) - w_R\, H(R)$。
Gain Ratio	得分为信息增益除以 SplitInfo；$\text{SplitInfo} = -w_L \log_2(w_L) - w_R \log_2(w_R)$。
Gini	$G(y) = 1 - \Sigma\, p_c^2$；得分 = $G(y) - w_L\, G(L) - w_R\, G(R)$。
Classification Error	$E(y) = 1 - \max(p_c)$；得分 = $E(y) - w_L\, E(L) - w_R\, E(R)$。

实验结果与结构比较

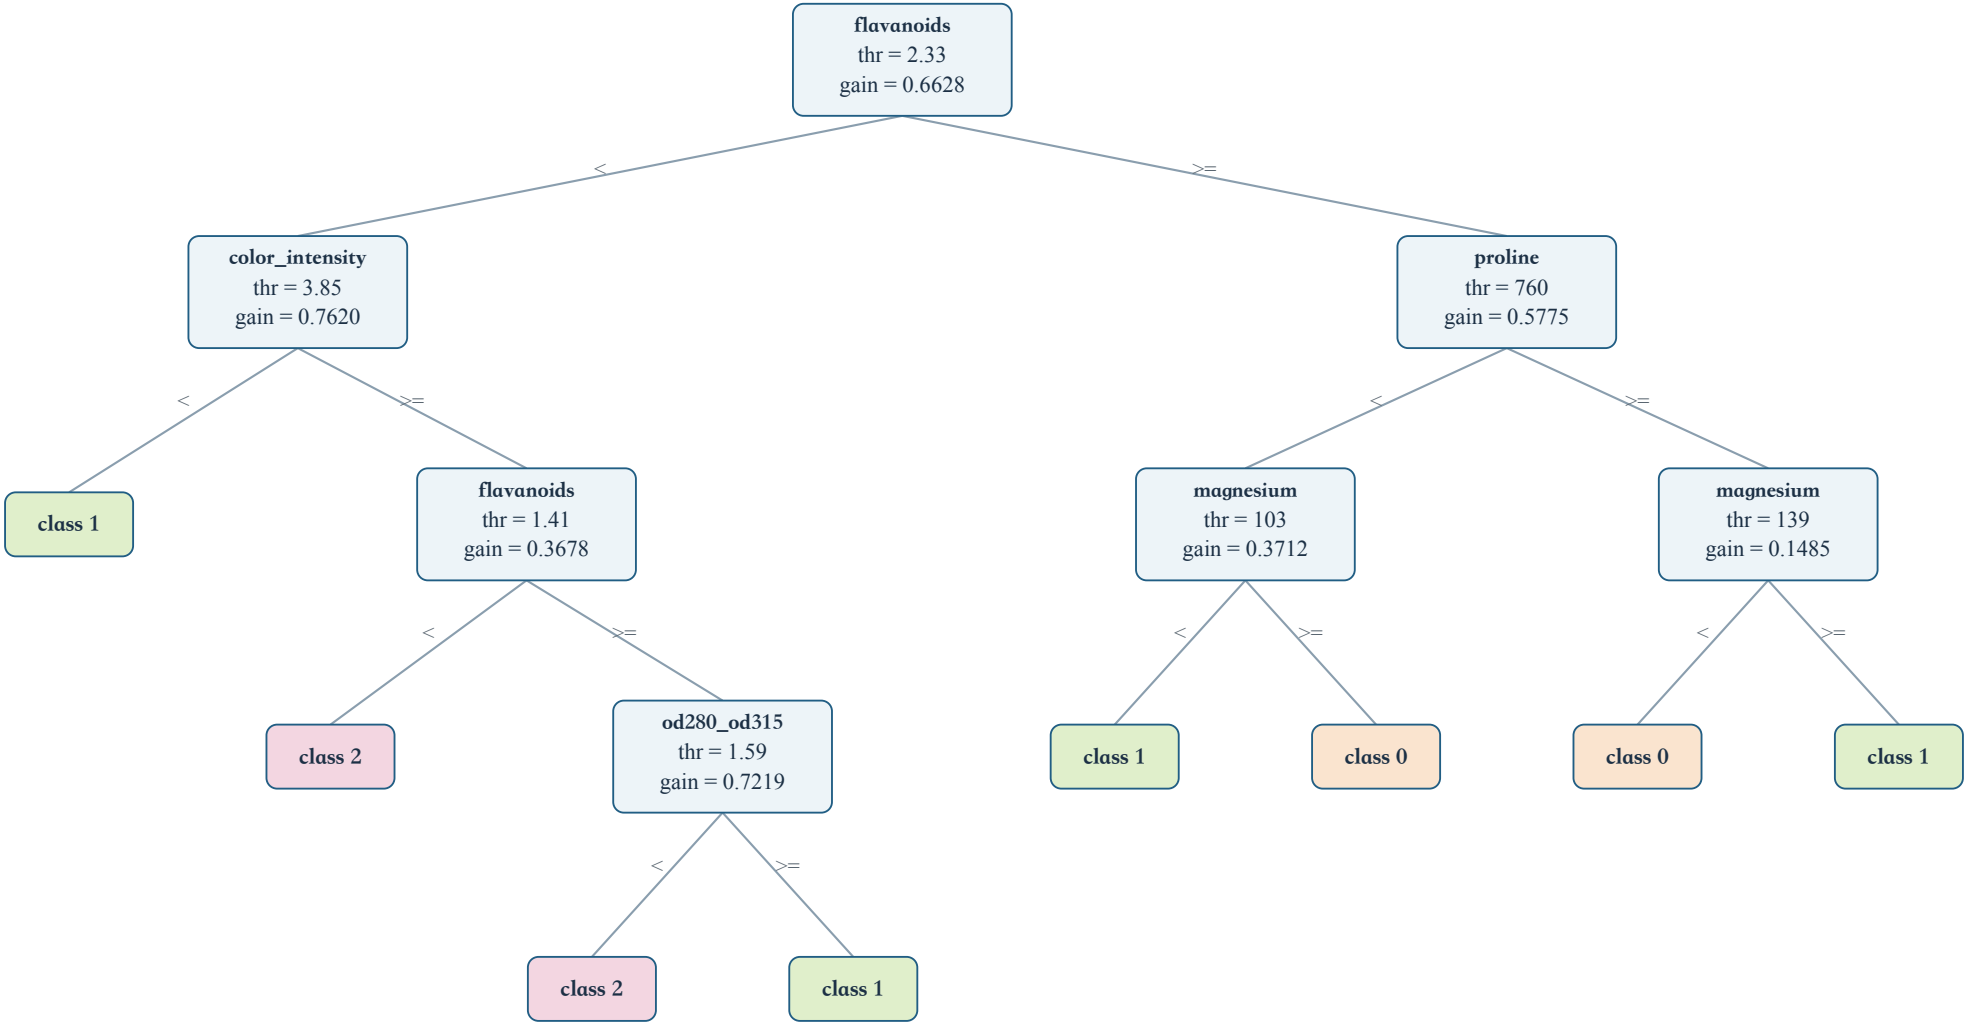
准则	训练正确数	测试正确数 / 准确率	深度	叶节点
info_gain	142/142	33/36 = 0.9167	5	8
info_gain_ratio	142/142	34/36 = 0.9444	7	9
gini	142/142	31/36 = 0.8611	6	11
error_rate	140/142	32/36 = 0.8889	5	9

信息增益率在此次划分中表现最好（34/36），但树也最深；Gini 的叶节点最多（11），测试正确数最少（31/36）。因此，复杂度增加并不保证更好的泛化。

分类误差只关注最大类别比例，对其他类别分布变化不够敏感。框架要求分裂收益严格大于 0，所以一些仍包含混合标签的节点会停止分裂；本次训练正确数为 140/142，其他三种为 142/142。信息增益和增益率的根节点均为 flavanoids，但阈值不同；Gini 和分类误差的根节点为 proline。

Part 2 · 树结构 / info_gain

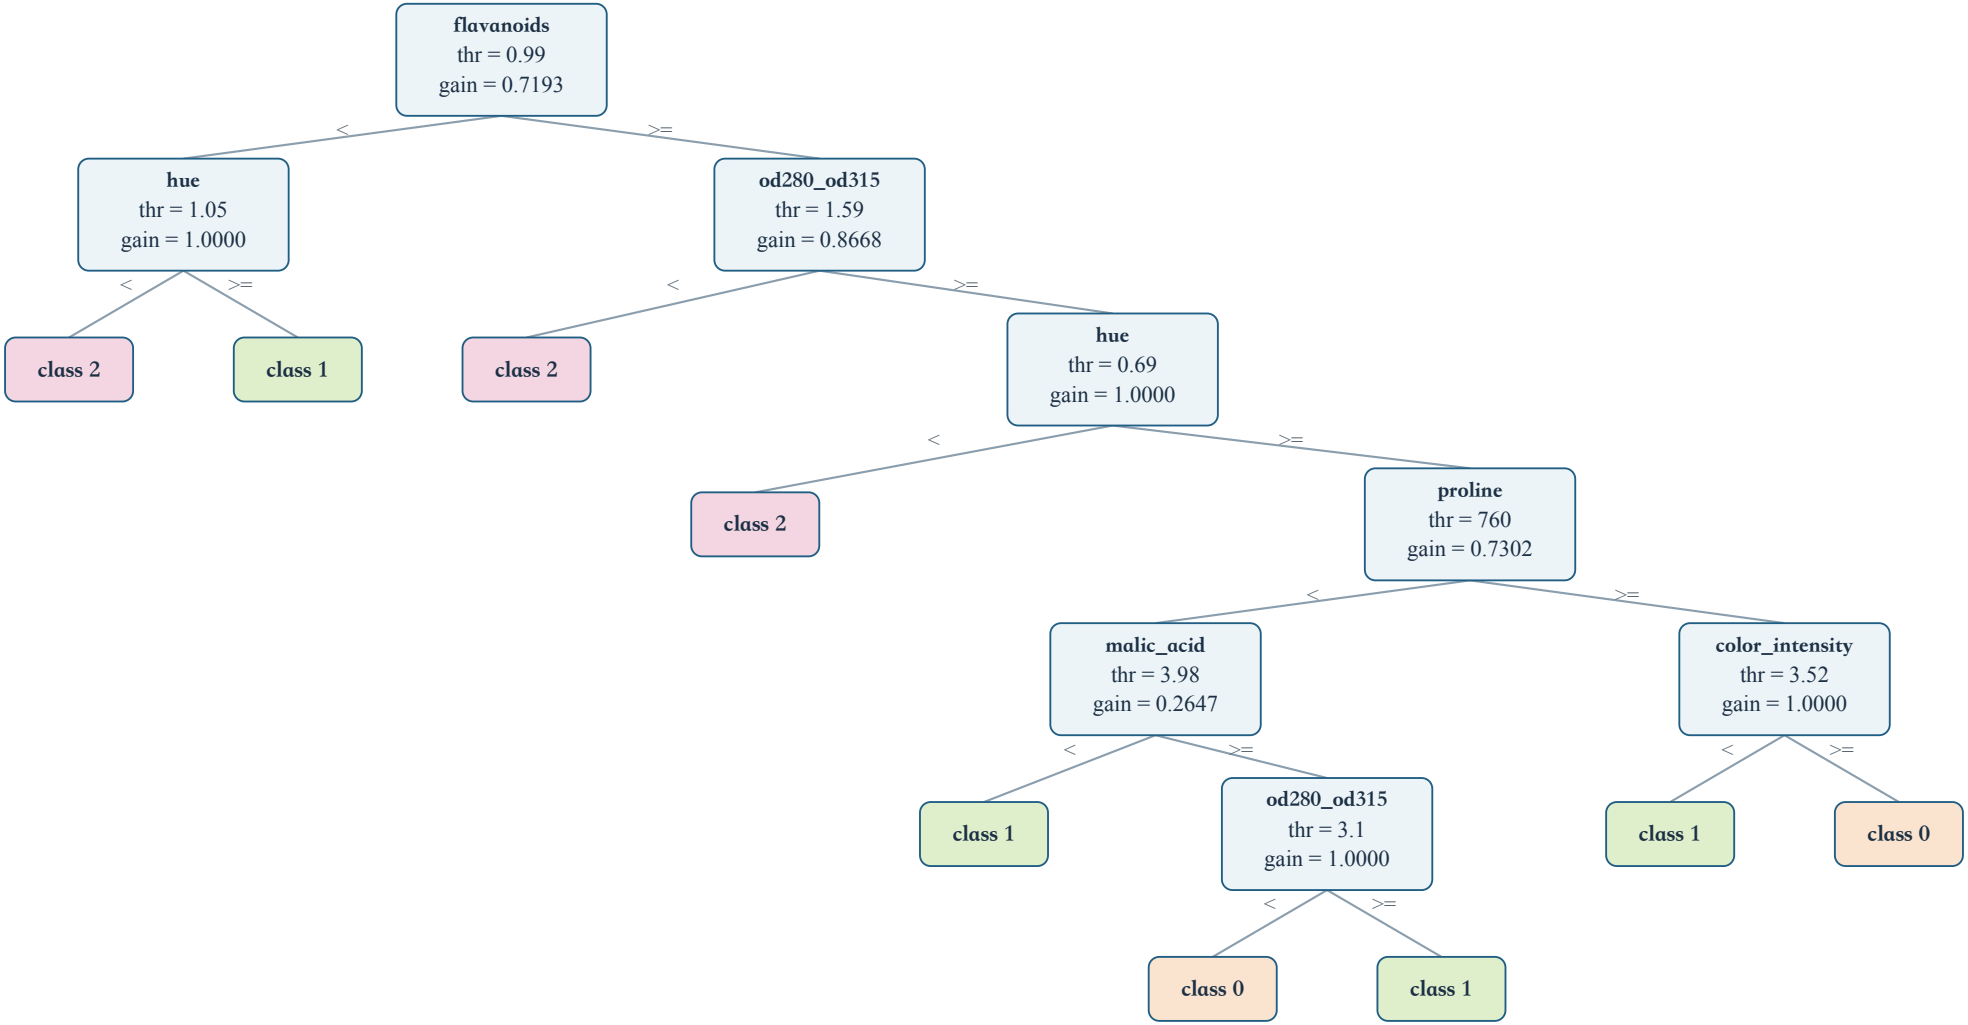
测试准确率 33/36 = 0.9167；深度 5；叶节点 8。



thr：分裂阈值；gain：当前准则的分裂得分；class：叶节点预测类别。各准则得分量纲不同。

Part 2 · 树结构 / info_gain_ratio

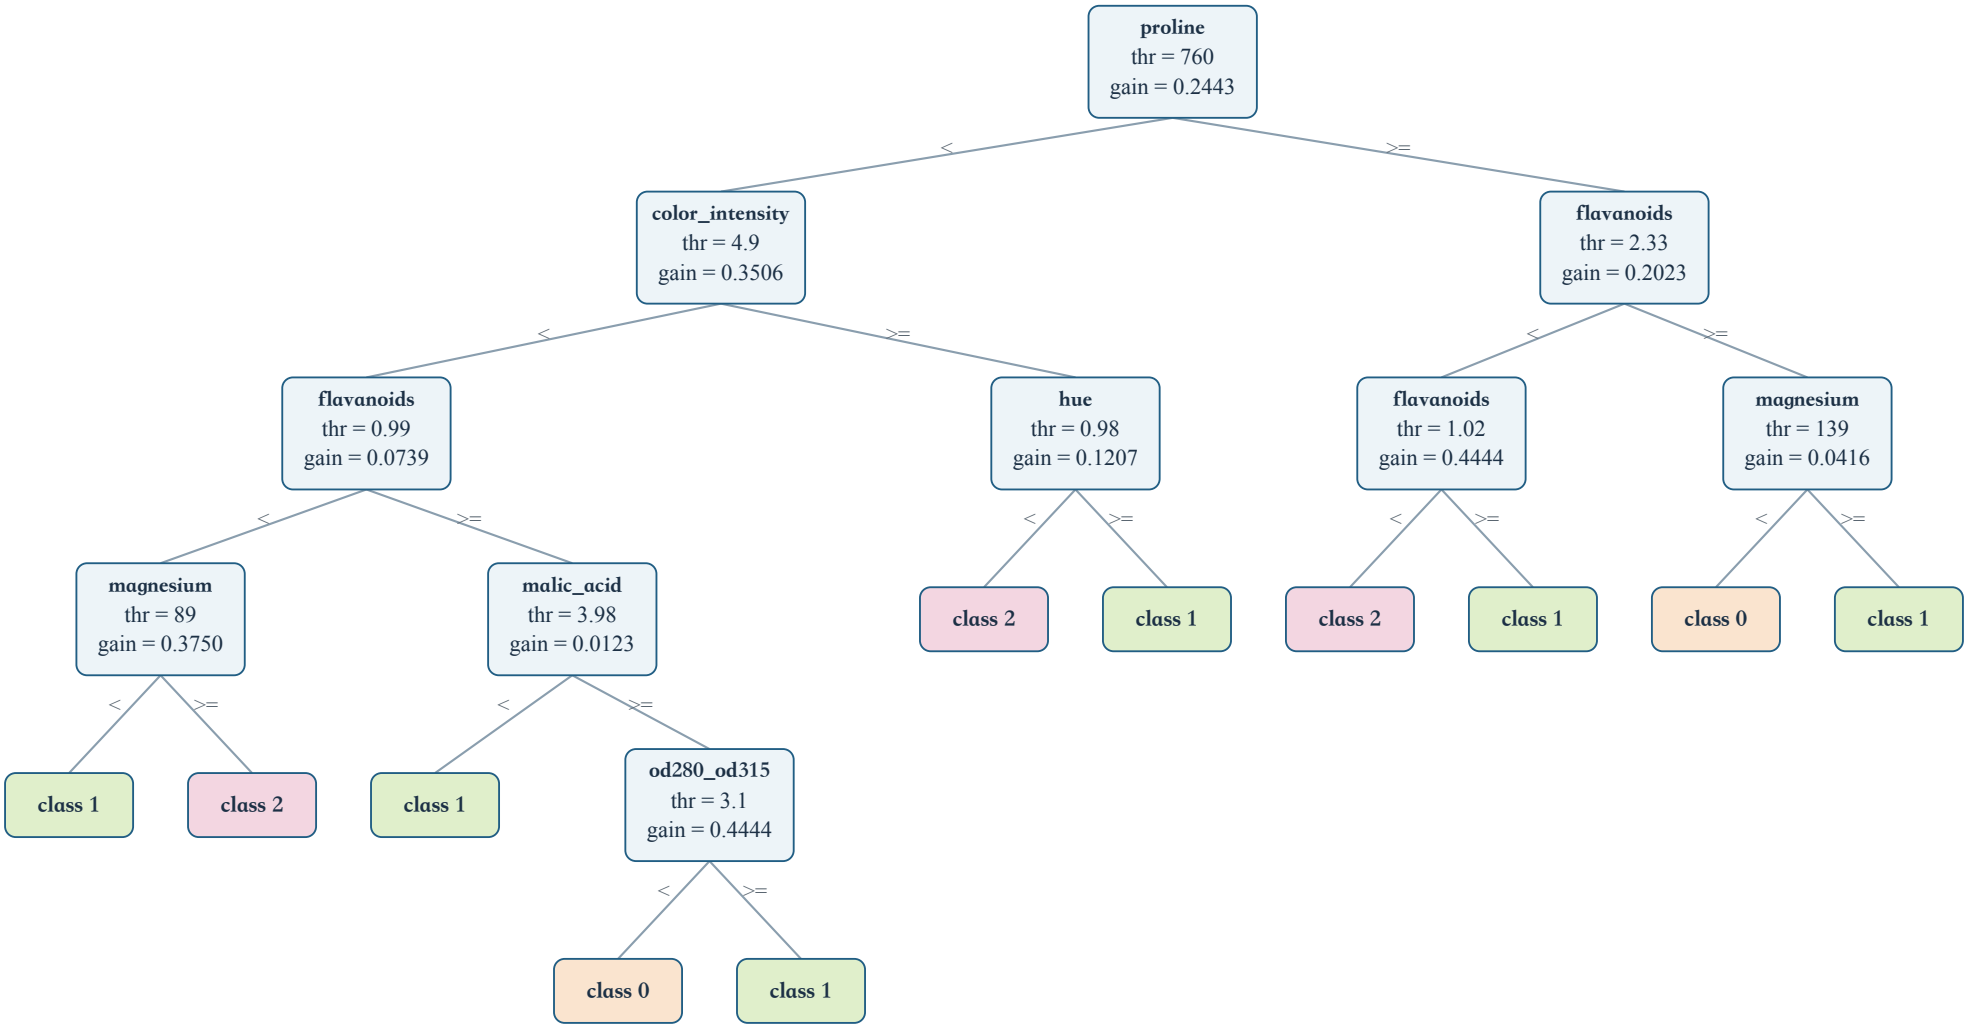
测试准确率 34/36 = 0.9444；深度 7；叶节点 9。



thr：分裂阈值；gain：当前准则的分裂得分；class：叶节点预测类别。各准则得分量纲不同。

Part 2 · 树结构 / gini

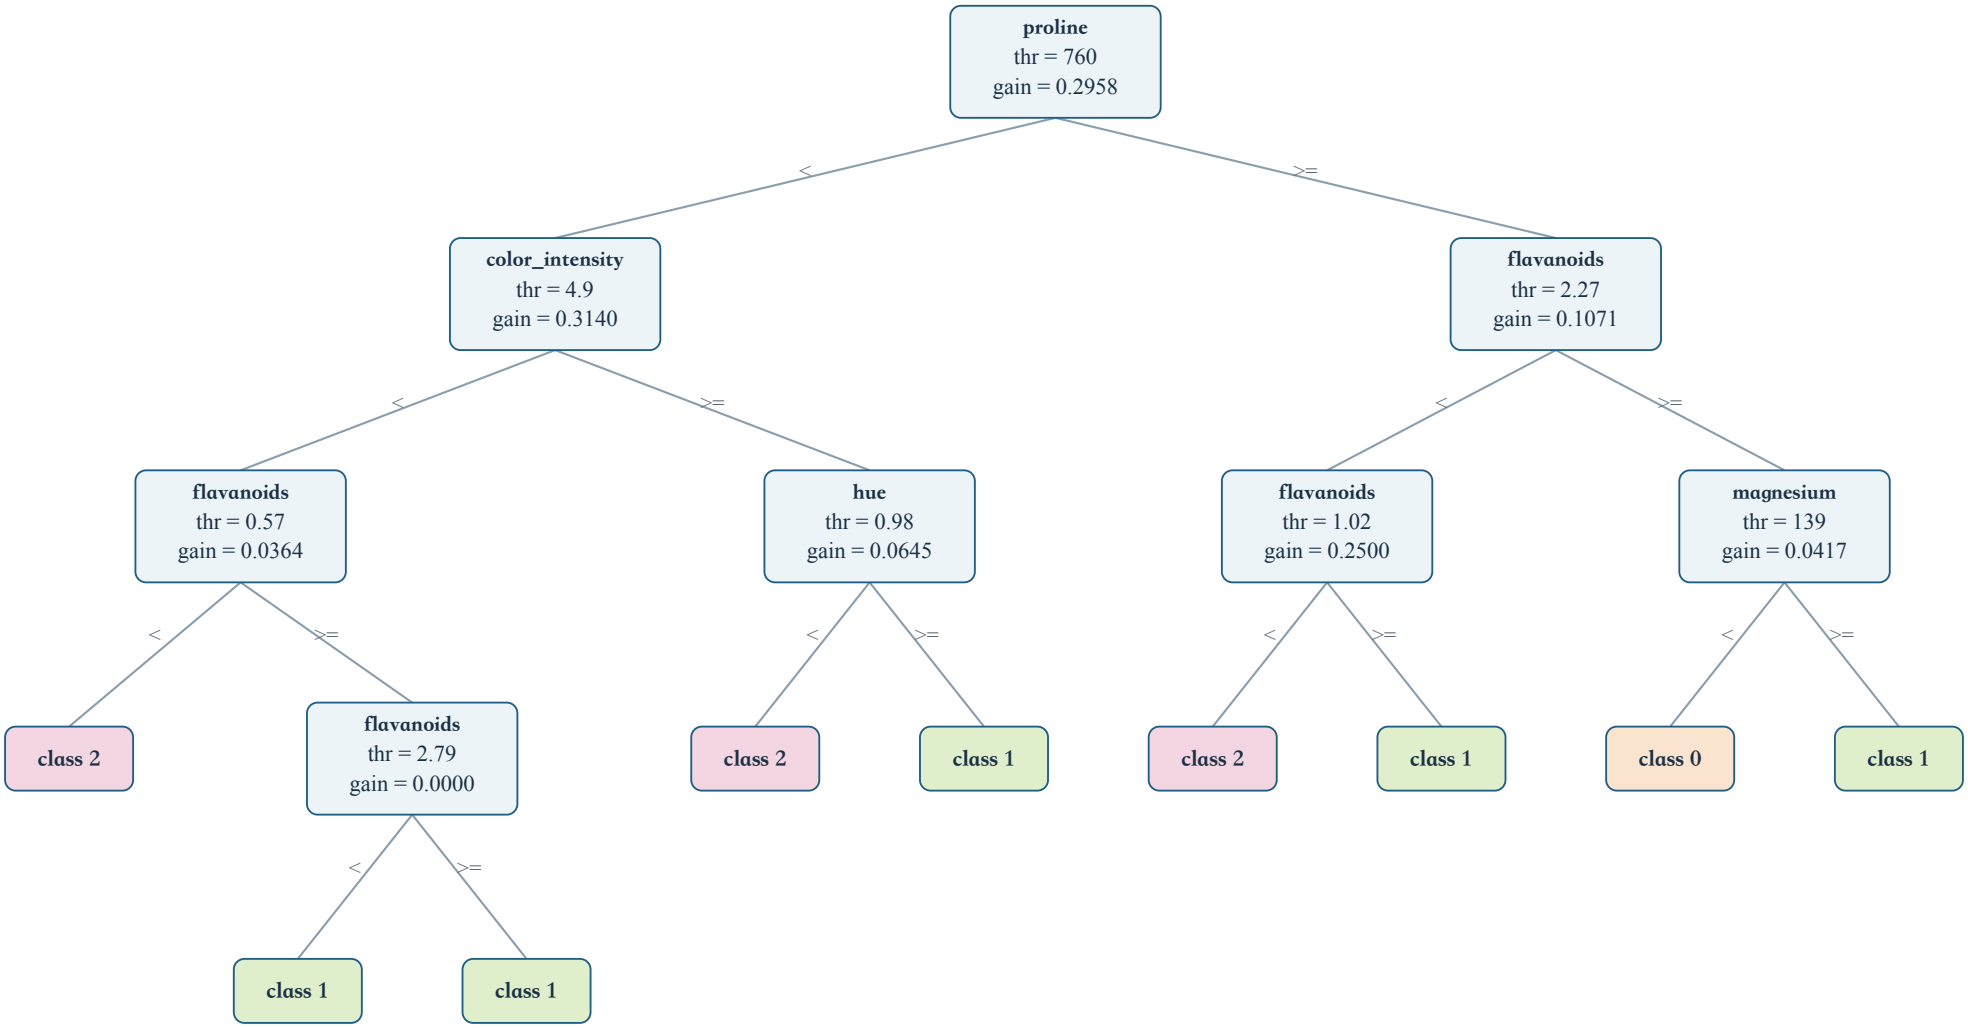
测试准确率 31/36 = 0.8611；深度 6；叶节点 11。



thr：分裂阈值；gain：当前准则的分裂得分；class：叶节点预测类别。各准则得分量纲不同。

Part 2 · 树结构 / error_rate

测试准确率 32/36 = 0.8889；深度 5；叶节点 9。



thr：分裂阈值；gain：当前准则的分裂得分；class：叶节点预测类别。各准则得分量纲不同。

Part 3 kNN 实现与选参

实现与实验协议

L2 双循环逐对计算 $\mathrm{sqrt}(\Sigma(x_j - z_j)^2)$。向量化计算采用 $\|x\|^2 + \|z\|^2 - 2x \cdot z$，先将平方距离截断为非负值再开方，避免舍入误差产生 NaN。余弦距离为 $1 - (x \cdot z)/(\|x\| \|z\|)$，先归一化再矩阵相乘，并将相似度限制在 [-1, 1]。零向量与任意向量的相似度约定为 0，距离为 1。

对距离作稳定排序，取前 k 个近邻，以出现次数最多的整数标签作为预测；标签票数相同则返回最小标签。等距离的近邻按原训练顺序排列。k 必须是 1 到训练样本数之间的整数。

候选 k 扩展为 $1 \le k \le 250$ 的所有整数，也包括偶数。仅用 250 条训练样本预测验证集并选择准确率最高的 k，平局时取较小 k。之后合并训练集与验证集共 375 条样本，用已选 k 预测测试集。边界图额外展示 k=375 的退化情况，该值不参与验证集选参。

验证曲线的数值（代表性 k）

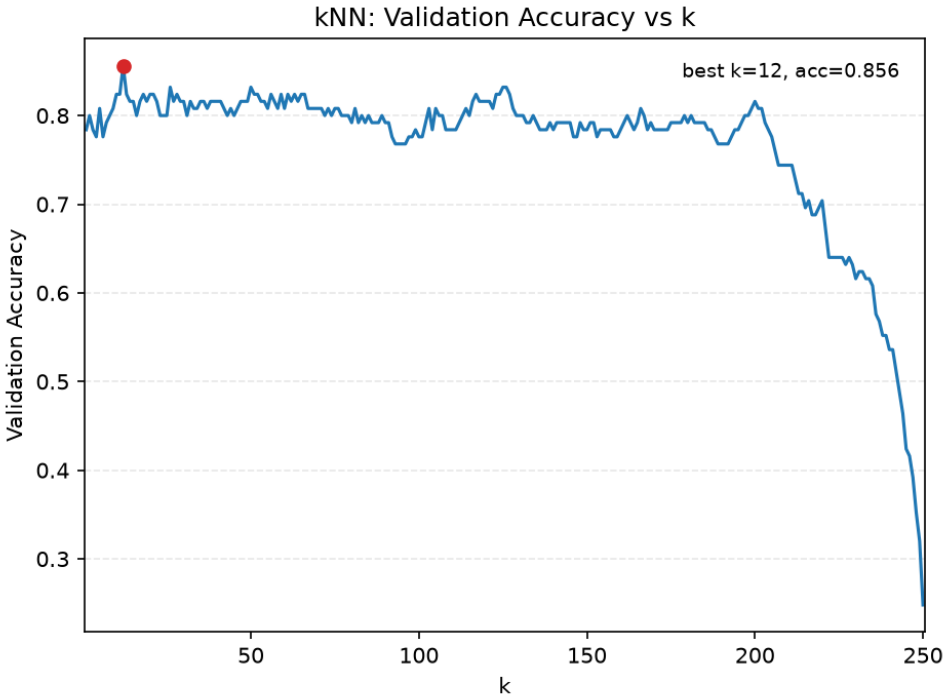
k	L2 验证准确率	Cosine 验证准确率
1	0.7840	0.7120
11	0.8240	0.8160
12	0.8560	0.8160
13	0.8240	0.8240
51	0.8240	0.7840
101	0.7760	0.7600
151	0.7920	0.7040
201	0.8080	0.5440
225	0.6400	0.4880
250	0.2480	0.2480

距离	最优 k	验证正确数 / 准确率	测试正确数 / 准确率
12	12	107/125 = 0.8560	97/125 = 0.7760
cosine	13	103/125 = 0.8240	96/125 = 0.7680

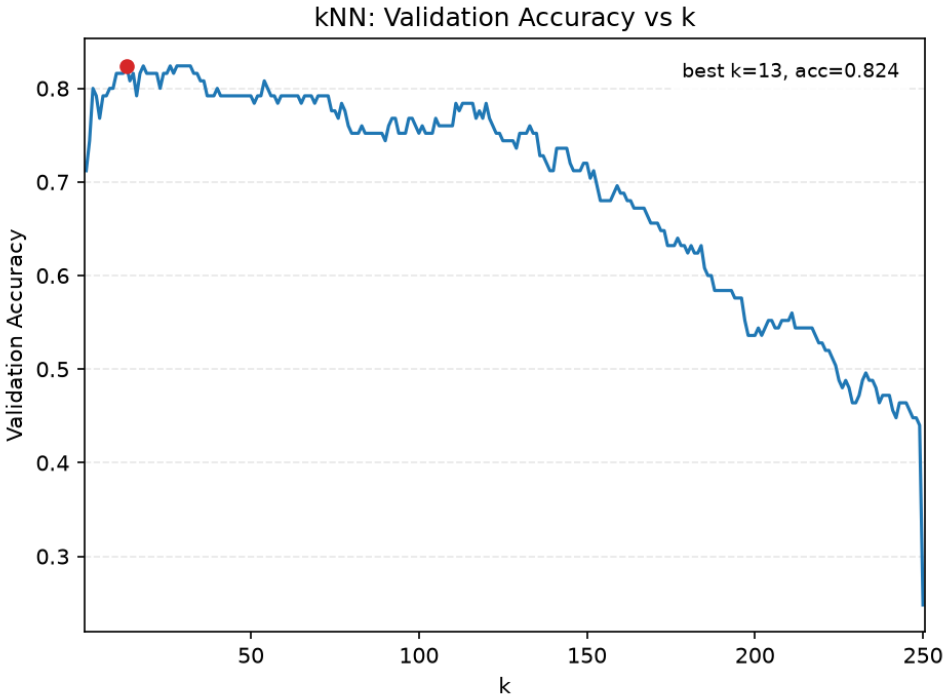
L2 的验证最优值变为 k=12、0.8560；对应测试准确率为 0.7760，低于原 k=11 的 0.8080。Cosine 在 k=13, 18, 26, 28, 29, 30, 31, 32 时均达到 0.8240，按平局规则仍选 13，测试准确率保持 0.7680。选参依据始终为验证集，验证表现提高不保证测试表现同步提高。

Part 3 Validation Accuracy vs k

L2



Cosine

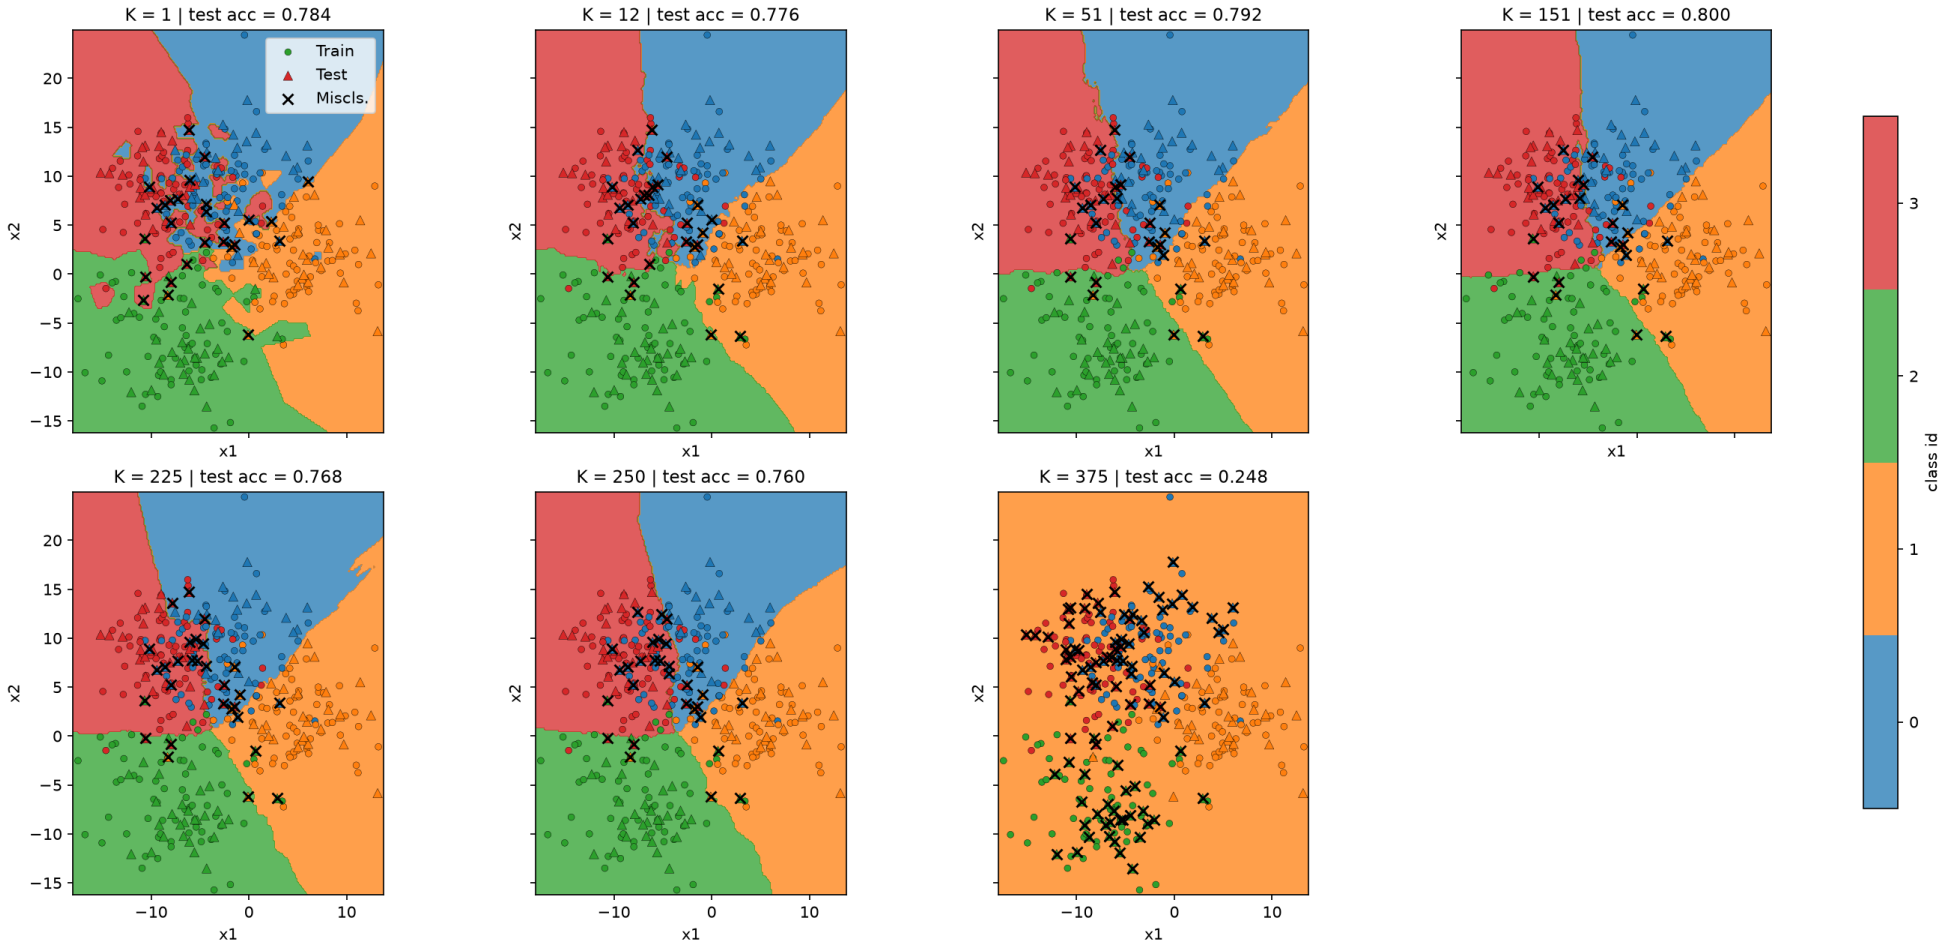


L2 在 k=12 达到 0.8560，之后存在波动；增大到 k=225 时验证准确率降至 0.6400。Cosine 在 k=13 首次达到最高值 0.8240，增大到 k=151 时降至 0.7040，k=225 时为 0.4880。两种距离在 k=250 时均降至 0.2480，已经明显劣化。

验证时训练集只有 250 条样本，k=250 会对全部训练标签投票，所有验证点均预测为类别 1，因此正确数为 31/125。过大的邻域掩盖局部类别结构，模型退化为固定类别预测，表现出明显欠拟合。

Part 3 · 决策边界 / L2

圆点：原训练样本；三角形：测试样本；黑色叉号：误分类测试点；背景色：预测类别。

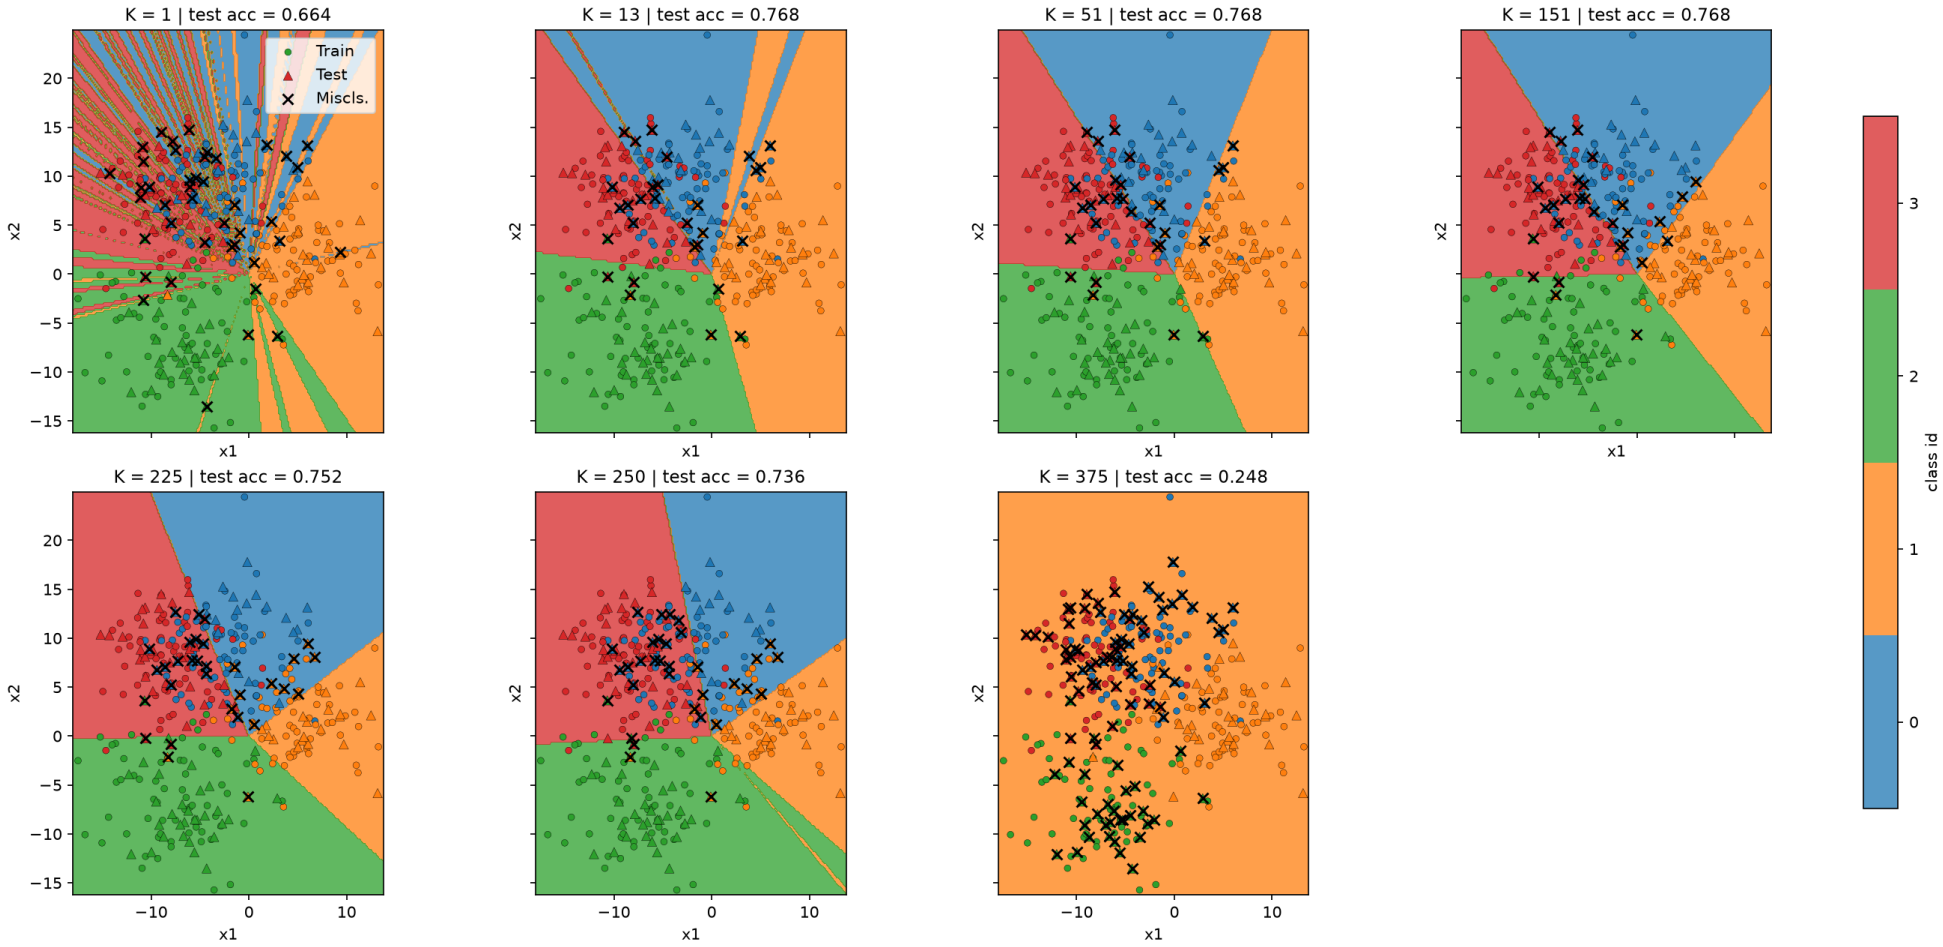


k=1 时边界出现较多细碎区域和局部小岛，对单个训练样本较敏感，体现较高方差及过拟合倾向。k 增大后区域更平滑，小岛减少；选出的 k=12 在测试集上预测正确 97/125 条（77.6%），仍有 28 个误分类点。

更大的 k 会使局部投票更稳定，也可能抹平真正的局部结构。边界模型使用 375 条训练及验证样本，k=250 的测试准确率仍为 0.7600；继续到 k=375，边界完全变为类别 1，测试准确率降至 31/125 = 0.2480，表明明显欠拟合。

Part 3 · 决策边界 / Cosine

圆点：原训练样本；三角形：测试样本；黑色叉号：误分类测试点；背景色：预测类别。



Cosine 只比较方向，同一条从原点出发的射线上，非零查询点拥有相同的距离排序，因此边界呈放射状。k=1 时有许多窄条带；较大的 k 减少条带数量，但仍丢失径向位置差异。k=13 测试正确 96/125 条（76.8%），误分类 29 条。

在这组数据上，新选出的 L2 模型比 Cosine 多预测正确 1 条（高 0.8 个百分点）。继续增大邻域，k=250 时 Cosine 的测试准确率为 0.7360；k=375 时所有点均预测为类别 1，测试准确率降至 31/125 = 0.2480，边界退化为单一区域。